

Guía de uso del Dashboard

K-Salud Analytics — Customer Intelligence

Proyecto Final · Gestión de Datos · UAX 2026 Álvaro González Fernández Documento de apoyo a la exposición oral

1. Qué es y para qué sirve

K-Salud Analytics es el entregable final del proyecto: una aplicación web que **convierte el Data Warehouse en decisiones de negocio**. La empresa ficticia "K-Salud" comercializa productos de salud y necesita responder cuatro preguntas clave:

- ¿Quiénes son mis clientes y cuánto valen?
- ¿Quién está a punto de irse?
- ¿A quién llamo mañana por la mañana?
- ¿Qué tendencia lleva el negocio?

El dashboard responde a las cuatro preguntas con datos reales del DWH (5.750 clientes, 42.555 líneas de venta, 6 años de histórico) y un modelo predictivo entrenado con `scikit-learn` y `XGBoost`.

2. Cómo lanzarlo

Desde la raíz del proyecto:

```
`` pip install -r requirements.txt streamlit run dashboard.py ``
```

El dashboard se abre automáticamente en `http://localhost:8501`. La carga inicial tarda 2-3 segundos (lee el CSV de clientes, el `.pkl` del modelo y el DWH SQLite).

Si falta algún archivo, el dashboard muestra un mensaje claro indicando qué fase ejecutar antes (notebooks 4, 5 o 6). No revienta silenciosamente.

3. Estructura del dashboard

- **Cabecera** centrada con el título "K-Salud Analytics" y el subtítulo del proyecto.
- **6 pestañas** justo debajo del título, **centradas** y dispuestas como una barra de navegación con fondo beige.
- Cada pestaña funciona como una **página independiente** que se carga al hacer clic.
- **Sin sidebar** — el dashboard ocupa toda la pantalla.

Tip de exposición: menciona que las decisiones de UX (sin sidebar, tipografía Garamond, paleta beige) están alineadas con la idea de *data product* pensado para que un usuario de negocio pueda usarlo sin formación técnica.

4. Pestaña 1 — Visión General

Qué muestra

- **8 KPIs globales** en 2 filas: total clientes, ingresos totales (€9,7M), margen total (€3,9M), CLTV medio, CLTV mediano, ticket medio, % activos y return rate medio.
- **Insight clave** en banda dorada: el ~13 % de los clientes (VIP Champions) genera el grueso de los ingresos.
- **Cartera completa por segmento:** gráfico de burbujas (CLTV vs recencia, tamaño = frecuencia, color = segmento) más donut de distribución de segmentos.
- **Ingresos por segmento + Curva de Pareto:** muestra cuánto valor concentra qué porcentaje de clientes.
- **Tabla resumen por segmento** con 11 columnas para una vista comparativa de un solo vistazo.

Qué puedes decir

"Esta primera vista responde a la pregunta '¿cómo está mi cartera?'. Tenemos 5.750 clientes que generan 9,7 millones de euros en ingresos y casi 4 millones de margen. Pero lo interesante está en la asimetría: la diferencia entre la **media** y la **mediana** del CLTV es de varios miles de euros, lo que ya nos avisa de que hay una cola larga de clientes muy valiosos. La curva de Pareto a la derecha lo confirma: aproximadamente el 13 % de los clientes — los VIP Champions — concentra cerca del 80 % de los ingresos."

5. Pestaña 2 — Análisis de Segmentos

Qué muestra

- **Selector horizontal** con los 4 clusters: VIP Champion, Regular Activo, Perdido, Devolutivo.
- **8 KPIs específicos** del segmento elegido (clientes, % cartera, CLTV medio, frecuencia, return rate, ingresos, mediana, churn risk).
- **Histograma de CLTV** del segmento (escala log10 para apreciar la cola).
- **Radar de 4 ejes**: perfil del segmento vs media global (Valor, Frecuencia, Recencia, Calidad).
- **Boxplot comparativo** CLTV del segmento vs el resto de la cartera.
- **Distribución de estado de churn** dentro del segmento (Activo / En riesgo / Perdido).
- **Tabla comparativa numérica** con la columna " Δ relativo" (% diferencia vs el resto).
- **Top 20 clientes** del segmento con email.

Qué puedes decir

"Aquí cambiamos de zoom: en lugar de mirar toda la cartera, miramos cada uno de los cuatro segmentos por separado. Si selecciono **VIP Champion**, el radar dispara en valor económico y frecuencia, y la tabla comparativa nos dice que su CLTV es varios cientos de veces el de la media. En cambio, si selecciono **Devolutivo**, el radar es muy plano excepto en una cosa: una tasa de devolución superior a 1, que es el patrón anómalo que justifica que estos clientes formen un cluster aparte."

6. Pestaña 3 — Plan de Choque

Esta es la **pestaña operativa** del dashboard: la que llevaría el equipo comercial.

Qué muestra

- **5 presets rápidos**: VIPs en riesgo, Recuperar VIPs perdidos, Devolutivos activos, Convertir Regular Activos, Reset.
- **Filtros manuales**: segmento, estado churn, rango CLTV.
- **KPIs de la selección**: clientes filtrados, ingresos generados, CLTV total, churn risk medio.
- **Distribución de churn risk + breakdown por segmento** de los filtrados.
- **Top 20 por prioridad estratégica** ($\text{CLTV} \times \text{churn_proba}$) — la "lista de oro": clientes valiosos con alto riesgo de fuga.
- **Lista completa filtrada** con email y teléfono, **exportable como CSV**.
- **Calculadora de ROI + tabla de sensibilidad** con 8 escenarios (2 % a 25 % de éxito).

Qué puedes decir

"Hasta aquí hemos analizado. Ahora **actuamos**. Esta pestaña es la que usaría el equipo comercial: hago clic en 'VIPs en riesgo' y aparece el listado exacto de clientes de alto valor a punto de irse. La tabla de prioridad ordena por CLTV multiplicado por probabilidad de fuga, así que los primeros son los que tienen más euros en juego. Y la calculadora de ROI permite estimar antes de gastar: si contacto a estos clientes con un coste de 5 € y consigo recuperar al 5 %, el retorno es X. La tabla de sensibilidad da el rango de escenarios para defender la campaña ante dirección."

7. Pestaña 4 — Inteligencia del Modelo

Qué muestra

- **Estadísticas del modelo**: algoritmo (XGBoost), AUC test (1.0000), nº de features (6), fecha de corte.
- **Importancia de variables**: gráfico de barras horizontales + tabla con porcentajes.
- **Explicaciones en lenguaje de negocio** de cada feature.
- **Distribución global de churn_proba** (histograma con umbrales 30 % y 70 %).
- **Boxplot de churn risk por segmento**.
- **Matriz de confusión** (proxy contra `estado_churn == 'Perdido'`).
- **Curva ROC** con AUC proxy ≈ 0.995 .
- **Heatmap de correlación** entre las 9 variables del cliente.

Punto clave que TIENES que explicar

El AUC = 1.0 **no es un bug**. Es estructural del dataset:

- La gran mayoría de clientes son **one-shot** (compran una vez y no vuelven).
- Los **VIPs** compran constantemente (frecuencia ≈ 20 tickets).

- La variable **frecuencia** (que el modelo identifica como dominante con el **99 %** de la importancia) separa estos dos grupos casi de forma determinista.
- En un dataset real con clientes intermedios, el AUC bajaría sensiblemente.

Qué puedes decir

"Aquí explico cómo funciona la 'inteligencia' del dashboard. Entrenamos dos modelos —Random Forest y XGBoost— con features observables al cierre del periodo de observación. La métrica AUC sale igual a 1, y aquí quiero ser **muy honesto**: no es un error ni leakage. Como veis en el gráfico de importancia, la **frecuencia** se lleva el 99 % del peso. ¿Por qué? Porque el dataset tiene una polarización extrema: o eres VIP que compra cada semana, o eres comprador puntual que no vuelve. La frecuencia separa ambos grupos casi perfectamente. En un dataset real con clientes intermedios el AUC sería menor, pero la metodología y las features son las correctas. La acción accionable que se deriva del modelo es clara: **convertir al cliente one-shot en cliente recurrente** —conseguir esa segunda compra— es la palanca con mayor impacto."

8. Pestaña 5 — Evolución Temporal

Qué muestra

- **4 KPIs temporales**: periodo cubierto, ingresos del último año, crecimiento YoY, nuevos clientes del último año.
- **Ventas mensuales + acumulado** en doble eje (barras = mes, línea acumulada).
- **Nuevos clientes por mes** (barras).
- **Ticket medio mensual** (línea con área).
- **Heatmap calendario año × mes** de ingresos.
- **Análisis de cohortes** por año de alta: tamaño de cohorte + CLTV medio vs mediano.
- **Estacionalidad**: ingresos por día de la semana + por mes del año.

Qué puedes decir

"Esta pestaña responde a '¿hacia dónde va el negocio?'. Vemos un crecimiento sostenido en los seis años cubiertos, con estacionalidad clara —los picos están en X días de la semana— y, lo más interesante para retención, el análisis de cohortes: las cohortes de 2020-2021 tienen un CLTV medio mucho mayor que las nuevas. Eso es **esperable** porque llevan más tiempo comprando, pero también nos dice que invertir en retención de las cohortes nuevas ahora se va a notar en su CLTV dentro de unos años."

9. Pestaña 6 — Arquitectura de Datos

Qué muestra

Cierra el ciclo técnico mostrando los artefactos del proyecto:

- **Diagrama Entidad-Relación** del esquema OLTP de origen (17 tablas).
- **Modelo dimensional Star Schema** del DWH (1 fact + 5 dim).
- **Tabla de filas** por entidad.

Qué puedes decir

"Termino con la arquitectura para cerrar el círculo. Estos diagramas muestran el viaje del dato: desde el modelo relacional original con 17 tablas normalizadas, hasta el esquema en estrella del DWH con una tabla de hechos y cinco dimensiones. El paso intermedio es un proceso ETL documentado en la memoria. Toda la información del dashboard sale del DWH, no del OLTP, que es exactamente lo que la asignatura nos pide: **separar el sistema transaccional del sistema analítico**."

10. Guión sugerido para la exposición (≈ 6 minutos)

Apertura — 30 s

"Buenos días. Mi proyecto es K-Salud Analytics: un dashboard que toma el Data Warehouse construido en las fases anteriores y lo convierte en una herramienta de decisión accionable para el equipo comercial. El recorrido será de unos seis minutos: enseñó cada pestaña y explico qué pregunta de negocio responde."

Demo — 4 a 5 minutos

Pestaña	Tiempo	Mensaje clave
Visión General	45 s	Panorama global, asimetría VIP / one-shot, Pareto
Análisis de Segmentos	60 s	Selecciona VIP, después Devolutivo; comenta el radar
Plan de Choque	60 s	Preset 'VIPs en riesgo', tabla prioridad, calculadora ROI
Inteligencia del Modelo	60 s	AUC = 1 explicado, importancia de la frecuencia
Evolución Temporal	45 s	Cohortes y estacionalidad
Arquitectura	30 s	Cierre técnico con los diagramas

Cierre — 30 s

"En resumen: el proyecto cubre el ciclo completo desde la base transaccional hasta una aplicación accionable. La memoria técnica documenta cada decisión —por qué Star Schema, por qué $k = 4$, por qué XGBoost— y el dashboard pone los resultados en manos de quien necesita actuar. Quedo abierto a preguntas."

11. Preguntas frecuentes — respuestas preparadas

¿Por qué un AUC perfecto? ¿No es sospechoso?

Sí, lo es a primera vista. Pero el dataset es muy polarizado: clientes one-shot vs VIPs recurrentes. La frecuencia separa ambos grupos casi de forma determinista. Lo importante no es el número de AUC sino la metodología: split temporal correcto, sin data leakage de futuro, features observables al corte. En un dataset real con clientes intermedios el AUC bajaría.

¿Por qué hay clientes con Return Rate > 1?

Es una limitación del alcance temporal del dataset. Las ventas registradas cubren un periodo concreto, pero las devoluciones pueden corresponder a compras anteriores no contabilizadas. No es un error: identificamos esos ~440 clientes como un cluster propio (Devolutivo).

¿Por qué $k = 4$ si el silhouette dice $k = 3$?

Trade-off entre métrica estadística e interpretabilidad de negocio. Con $k = 3$ perdemos la separación entre "Perdidos normales" y "Devolutivos", que requieren acciones comerciales muy distintas. Sacrificamos 0,05 puntos de silhouette a cambio de un cluster accionable.

¿Por qué SQLite en lugar de PostgreSQL para el DWH?

Portabilidad del entregable. El DWH va incluido como archivo en el repositorio (saleshealth_dwh.db) y cualquiera puede abrirlo sin levantar un servicio. En producción sería un MPP cloud (BigQuery, Snowflake, Redshift). El esquema dimensional y el ETL son agnósticos del motor.

¿Por qué etiquetado fijo de clusters y no dinámico?

KMeans con random_state=42 es determinista: los IDs son estables entre ejecuciones. Hardcodear el mapeo es más simple y elimina ambigüedades como las que aparecían con el etiquetado dinámico (clusters distintos cayendo en el mismo cuadrante y desempatóndose con sufijos numéricos).

¿Cómo escalaría a más datos?

El cuello de botella sería el ETL. Hoy es un script monolítico en pandas; en producción usaría un orquestador (Airflow, Dagster) con cargas incrementales por fecha. El modelo predictivo se reentrenaría periódicamente con los datos nuevos.

¿Qué harías en la siguiente iteración?

Tres cosas. Primero, integrar return_item en el DWH como segunda tabla de hechos para abrir análisis de calidad de producto. Segundo, alinear product con central_product por SKU en lugar de por nombre, mejorando la cobertura de unit_cost. Tercero, sustituir el modelo por uno entrenado sobre clientes intermedios para tener AUCs más realistas.