

Proyecto Final

Gestión de Datos

Construcción de un Entorno Analítico y Cálculo de Métricas de Cliente

Documento didáctico — del problema de negocio a la segmentación con Machine Learning

Álvaro

Ingeniería Matemática · UAX · Curso 2025-2026

Índice

Parte I El problema y su contexto

1. La empresa y su modelo de negocio
2. El caos de los datos: los sistemas operacionales
3. Por qué los datos operacionales no sirven para analizar

Parte II Conceptos clave: la teoría que necesitas

4. Qué es un Data Warehouse (DWH)
5. El Modelo Dimensional y el esquema en estrella
6. Qué es un proceso ETL
7. Métricas de cliente: CLTV, Churn y Return Rate
8. Machine Learning: la idea básica
9. Reducción de dimensiones con PCA
10. Clustering con K-Means

Parte III La solución implementada

11. Arquitectura general del proyecto
12. Fase 1 — Exploración del origen
13. Fase 2 — Diseño del Star Schema
14. Fase 3 — Pipeline ETL
15. Fase 4 — Cálculo de métricas
16. Fase 5 — PCA y K-Means

Parte IV Resultados y conclusiones

17. Interpretación de los segmentos
18. Recomendaciones de negocio
19. Cómo encaja todo: el cuadro completo

El problema y su contexto

Antes de hablar de bases de datos, ETL, clustering o ningún otro tecnicismo, conviene entender bien **de dónde partimos**. Toda la solución técnica que vamos a construir tiene sentido solo en la medida en que resuelve un problema real de una empresa real. Si no entiendes el problema, las herramientas son ruido. Si lo entiendes, todo cobra sentido.

1. La empresa y su modelo de negocio

Imagina una empresa española dedicada a la **venta de productos relacionados con la salud y el bienestar**: vitaminas, suplementos alimenticios, productos para el cuidado personal, tensiómetros, productos de farmacia, etc. La empresa comercializa un catálogo de unos 50 productos a través de una red de tiendas físicas distribuidas por la ciudad y un almacén central que abastece a esas tiendas.

El sector en el que opera es **enorme y está en pleno crecimiento**. El mercado mundial de productos de salud y bienestar arranca 2026 con un valor estimado de 12.482 mil millones de dólares y se espera que siga creciendo durante la próxima década. La mitad de ese crecimiento procede de una mayor concienciación de los consumidores sobre su salud, junto con tendencias como la hiper-personalización, la integración con tecnología wearable y el envejecimiento de la población.

En este contexto competitivo, **conocer al cliente** deja de ser un lujo: es una ventaja estratégica. La empresa que entienda mejor a qué tipo de cliente vende, cuánto vale cada uno, qué patrones siguen sus compras y quién está a punto de abandonarla, podrá personalizar su oferta, retener a los más rentables y dejar de malgastar recursos con los que ya no van a volver.

Datos reales con los que vamos a trabajar

17 tablas en la base de datos operacional · **5.750** clientes · **20.000** ventas · **42.555** líneas de venta · **2.330** devoluciones · **50** productos · **20** tiendas · **~9,7 millones de €** facturados · **~3,9 millones de €** de margen total.

En total, **71.934 filas** repartidas en 17 tablas y **96 columnas distintas**.

2. El caos de los datos: los sistemas operacionales

El problema con el que se encuentra la empresa es muy típico y muy real: **la información está fragmentada en sistemas distintos que no se hablan entre sí**. Cada departamento tiene su propio software y, dentro de cada software, los datos se estructuran como conviene a las operaciones del día a día, no al análisis posterior.

En nuestro caso concreto, los datos llegan repartidos en cuatro grandes tipos de sistemas, los llamados *sistemas operacionales* u **OLTP** (*Online Transaction Processing*):

Sistema	Tablas que lo componen y para qué sirve
ERP — Ventas	Las tablas sale y sale_item . Cada vez que un cliente paga en caja, se crea una venta (sale) con varias líneas (sale_item, una por producto). Aquí también están offer y product_offer con las promociones aplicadas.
CRM — Clientes	La tabla customer . Información personal: nombre, email, teléfono, fecha de alta. Ningún dato analítico, solo identidad.
Logística	Las tablas store (tiendas), warehouse (almacenes), warehouse_location , central_inventory (stock central) e inventory (stock por tienda). Aquí se gestiona dónde está cada cosa.
Postventa	Las tablas return_item y return_reason . Cuando un cliente devuelve un producto, queda registrado aquí con su motivo.
Catálogo	Las tablas product , category , brand y central_product . El maestro de productos, sus categorías y marcas.
Geografía	La tabla city_zone con los distritos de Madrid y sus orientaciones.

■ Una analogía para entenderlo

Piensa en una casa donde el dueño guarda **las facturas en el cajón del salón**, **los recibos del banco en una caja del trastero**, **los gastos del coche en la guantera** y **las cuentas del supermercado en un sobre de la cocina**. Todo está, pero responder "¿cuánto gasté el año pasado en total?" exige levantarse, abrir cuatro sitios distintos, sumar a mano y rezar para no haberse dejado nada.

Una empresa con datos dispersos vive ese problema todos los días, pero multiplicado por miles de clientes y millones de transacciones.

3. Por qué los datos operacionales no sirven para analizar

Aquí hay un punto que conviene entender bien, porque es la base teórica de todo el proyecto: **los datos operacionales y los datos analíticos no son lo mismo, ni se diseñan igual.**

Datos operacionales (OLTP)

Están diseñados para que la empresa **opere**. Cuando un cliente paga, el sistema tiene que insertar una fila en `sale`, varias en `sale_item`, descontar stock en `inventory`... y todo eso **en milisegundos, sin errores y sin duplicados**. Para conseguirlo, los datos se guardan *normalizados*: cada información existe en un único sitio y las tablas se relacionan mediante claves. Esto hace las escrituras rapidísimas y consistentes, pero las lecturas analíticas terriblemente lentas.

Datos analíticos (OLAP)

Están diseñados para que la empresa **aprenda**. Aquí ya no nos importa tanto que cada inserción sea instantánea, sino poder responder preguntas complejas como "*¿qué clientes de la zona norte de Madrid compraron vitaminas el último trimestre y aún no han devuelto nada?*" sin tardar media hora ni programar SQL acrobático. Para eso los datos se reorganizan *desnormalizados*: la información se duplica deliberadamente en pocas tablas grandes, sacrificando espacio en disco a cambio de velocidad de consulta y simplicidad.

Característica	OLTP (operacional)	OLAP (analítico)
Objetivo	Operar el negocio	Analizar el negocio
Operación típica	Insertar 1 venta	Sumar 1 millón de ventas
Estructura	Muchas tablas pequeñas, normalizadas	Pocas tablas grandes, desnormalizadas
Optimizado para	Escritura rápida	Lectura masiva
Ejemplo en este proyecto	PostgreSQL saleshealth con 17 tablas	SQLite saleshealth_dwh con 6 tablas

Tabla 1 · Diferencia entre datos operacionales y analíticos.

La conclusión es clara: **la base de datos operacional no es nuestro destino, es nuestro origen**. Necesitamos transformar esos datos en otra estructura distinta, pensada para el análisis. Esa estructura tiene un nombre: **Data Warehouse**. Y para llenarla necesitamos un proceso que extraiga datos del origen, los transforme y los cargue en el destino: el **ETL**. Pero antes de ver cómo se construye, vamos a entender qué son.

Conceptos clave: la teoría que necesitas

En esta segunda parte vamos a explicar, con lenguaje claro y analogías, **qué es cada una de las piezas teóricas** que componen el proyecto. El objetivo es que cuando llegues a la Parte III tengas clarísimo cada concepto y la implementación se vea como la consecuencia natural de la teoría, no como una receta opaca.

4. Qué es un Data Warehouse (DWH)

Un **Data Warehouse** (almacén de datos) es una base de datos especializada en el análisis. La definición clásica, debida a **Bill Inmon** (uno de los padres del concepto), dice que es:

"Una colección de datos orientada a un tema, integrada, no volátil y variable en el tiempo, diseñada para ayudar a la toma de decisiones."

Desglosamos esas cuatro propiedades porque cada palabra cuenta:

Orientada a un tema	El DWH se organiza alrededor de los temas de negocio (ventas, clientes, productos), no alrededor de los procesos técnicos de la empresa.
Integrada	Datos de muchos sistemas (ERP, CRM, postventa...) se unifican en formato, nombres y unidades. Si en el CRM el género es "M/F" y en el ERP es "H/M", en el DWH es uno solo.
No volátil	Los datos del DWH no se borran ni se sobrescriben . Una venta de hace cinco años sigue ahí intacta, porque el análisis histórico depende de eso.
Variable en el tiempo	Cada dato lleva siempre asociada una dimensión temporal : año, trimestre, mes, semana. Sin tiempo no hay análisis posible.

■ Analogía: el archivo histórico vs la mesa de trabajo

Una base de datos operacional es como la mesa de trabajo de un médico: lo que necesita *ahora mismo*, organizado para coger y soltar mil veces al día. Un Data Warehouse es como el archivo histórico del hospital: cada paciente, cada visita, cada tratamiento, organizados para que un investigador pueda preguntar "*¿cuántos pacientes diabéticos mayores de 60 ingresaron entre 2020 y 2025?*" y obtener la respuesta en segundos.

5. El Modelo Dimensional y el esquema en estrella

Una vez decidido que necesitamos un Data Warehouse, surge la pregunta: **¿cómo organizamos las tablas dentro de él?** La respuesta más extendida y exitosa la dio **Ralph Kimball** en los años 90 con el llamado **Modelo Dimensional**, también conocido como **esquema en estrella** (*star schema*).

La idea central

En vez de tener decenas de tablas relacionadas por todos lados (como en el OLTP), el modelo dimensional impone una estructura muy simple y muy potente:

- **Una tabla central llamada *tabla de hechos* (*fact table*)** donde cada fila es un evento medible del negocio: una línea de venta, un click, una llamada... Contiene **números** (importe, cantidad, margen) y referencias a las tablas de dimensiones.
- **Varias tablas de *dimensiones* (*dimension tables*)**, que describen el contexto del hecho: **quién** compró (cliente), **qué** compró (producto), **dónde** (tienda), **cuándo** (fecha), **en qué condiciones** (oferta).

Visualmente las dimensiones rodean a la tabla de hechos como puntas de una estrella. De ahí el nombre.

Por qué es genial este diseño

Simplicidad	Cualquier consulta se reduce a un JOIN entre la tabla de hechos y las dimensiones que necesite . Nada más. Cualquier persona del negocio entiende el esquema con verlo cinco minutos.
Velocidad	Como las dimensiones están desnormalizadas (tienen toda la info junta sin más tablas detrás), no hay que encadenar 6 JOINS como en el OLTP. La consulta vuela.
Granularidad clara	Cada tabla de hechos tiene una granularidad fija (en nuestro caso: <i>una fila por línea de venta</i>). Eso evita ambigüedades en los cálculos.
Pensado para BI	Herramientas de visualización como Power BI, Tableau o Looker están diseñadas para conectarse a esquemas en estrella casi sin configuración.

Star Schema vs Snowflake Schema

Existe una variante llamada **esquema en copo de nieve** (*snowflake*) en la que las dimensiones se vuelven a normalizar (por ejemplo, `dim_product` referencia a otra tabla `dim_category`). Es más limpio matemáticamente pero más lento. **Para casi todos los casos prácticos se prefiere el star schema** y eso es lo que usamos en este proyecto.

6. Qué es un proceso ETL

Si el Data Warehouse es la *fábrica de información*, el **ETL** es la *cadena de montaje* que la alimenta. ETL son las siglas de **Extract, Transform, Load**: las tres fases que recorre cualquier dato para pasar de los sistemas origen al DWH.

E — Extract	Extraer los datos de los sistemas origen: bases de datos operacionales, ficheros CSV, APIs, archivos Excel, servicios web... Cada origen habla un idioma distinto y el ETL tiene que entenderlos todos.
T — Transform	Transformar los datos para que tengan calidad y formato adecuados para el análisis. Aquí pasan muchas cosas: limpieza de nulos, unificación de formatos (por ejemplo, todas las fechas a YYYY-MM-DD), creación de campos derivados (como el margen = subtotal – unit_cost × quantity), eliminación de duplicados, validación de integridad referencial...
L — Load	Cargar los datos transformados en el Data Warehouse. Hay que respetar el orden (primero las dimensiones, después la tabla de hechos, porque la fact tiene claves foráneas que apuntan a las dims), gestionar errores y, en sistemas reales, decidir si la carga es <i>completa o incremental</i> .

■ Analogía: el ETL como una fábrica de embotellado

Imagina que tu empresa hace zumo natural. El **Extract** es ir a los huertos a recoger naranjas, manzanas y melocotones (cada uno con su forma, tamaño y estado). El **Transform** es lavarlos, pelarlos, exprimirlos, mezclarlos en las proporciones correctas y filtrar las pepitas. El **Load** es embotellar el zumo final, etiquetarlo y meterlo en el almacén ordenado por sabor y fecha. Si te saltas cualquiera de las tres fases, el resultado es incomible.

7. Métricas de cliente: CLTV, Churn y Return Rate

Una vez tenemos el Data Warehouse cargado, podemos calcular indicadores clave (KPIs) sobre los clientes. Vamos a explicar los tres que usamos en el proyecto.

7.1 CLTV — Customer Lifetime Value

Es probablemente la métrica más importante en marketing y retención. Mide **cuánto dinero genera un cliente para la empresa a lo largo de toda su relación comercial**. Un cliente que ha comprado una vez 20 € no es lo mismo que uno que lleva 5 años comprando 200 € al mes. El CLTV los distingue.

La fórmula que pide el enunciado del proyecto es:

$$\text{CLTV} = \text{Ingresos} \times \text{Margen} \times \text{Frecuencia} \times R$$

Donde cada componente significa:

Ingresos	Total facturado al cliente desde que es cliente. SUM(subtotal).
-----------------	---

Margen	Porcentaje de cada euro facturado que se queda como beneficio (ingresos – costes / ingresos). Si vendo a 10 € algo que me cuesta 6 €, mi margen es del 40 %.
Frecuencia	Número de tickets distintos que ha generado el cliente.
R (Lifetime)	Años transcurridos desde la primera hasta la última compra (mínimo 1).

7.2 Churn Risk — Riesgo de abandono

Churn significa *abandono*. Un cliente "churneado" es un cliente que se ha ido. El **Churn Risk** es una clasificación que estima qué cliente está activo, cuál se está enfriando y cuál ya se ha perdido. La definición que usamos:

Activo	Ha comprado en los últimos 180 días . Cliente sano.
En riesgo	No compra desde hace entre 180 y 365 días . Cliente que se está enfriando y conviene reactivar con una campaña antes de perderlo.
Perdido	Más de 365 días sin comprar. Hay que decidir si invertir en recuperarlo o aceptar que ya no volverá.

7.3 Return Rate — Tasa de devolución

Cociente entre las unidades devueltas y las unidades compradas por cada cliente. Útil para detectar clientes problemáticos (que devuelven todo lo que compran) o, al revés, productos defectuosos (si afectan a muchos clientes a la vez). Un return rate del 10 % significa que de cada 10 productos que compra, devuelve uno.

8. Machine Learning: la idea básica

El **Machine Learning** (aprendizaje automático) es una rama de la inteligencia artificial donde, en lugar de programar reglas explícitas, le damos a un algoritmo una gran cantidad de datos y dejamos que **él mismo descubra los patrones**. La diferencia es enorme:

- **Programación tradicional:** tú escribes las reglas. *"Si el cliente lleva más de un año sin comprar, márcalo como perdido."*
- **Machine Learning:** tú das los datos y el modelo aprende las reglas. *"Aquí tienes 5.000 clientes etiquetados como activos o perdidos, descubre tú qué los distingue."*

Tres grandes familias

El Machine Learning suele dividirse en tres grandes tipos según el tipo de problema:

Aprendizaje supervisado	Tienes ejemplos con respuesta correcta y entrenas un modelo para predecir esa respuesta en casos nuevos. Ejemplos: predecir el precio de una casa, clasificar emails como spam/no spam.
Aprendizaje no supervisado	Tienes ejemplos sin respuesta correcta : el algoritmo busca estructura oculta por sí solo. Ejemplos: agrupar clientes parecidos (clustering), reducir la dimensionalidad de los datos (PCA). Esto es lo que usamos en el proyecto.
Aprendizaje por refuerzo	Un agente aprende a tomar decisiones interactuando con un entorno y recibiendo recompensas o castigos. Ejemplos: AlphaGo, robots que aprenden a caminar.

■ Cuidado con la palabra "predicción"

Ni el clustering ni el PCA *predicen* nada en sentido estricto. Son técnicas **descriptivas** e **exploratorias**: agrupan o resumen datos que ya tienes. Predicción real ("este cliente se irá en 3 meses con 73 % de probabilidad") es aprendizaje supervisado, y eso queda fuera del alcance de este proyecto.

9. Reducción de dimensiones con PCA

PCA (*Principal Component Analysis*, Análisis de Componentes Principales) es una de las técnicas más conocidas del aprendizaje no supervisado. Resuelve un problema concreto: **tenemos muchas variables y no podemos visualizarlas todas a la vez**.

El problema que resuelve

En nuestro proyecto cada cliente se describe con 4 variables: CLTV, días desde última compra, frecuencia y return rate. Para visualizar 2 variables basta un gráfico XY; para 3 podemos usar 3D; pero **nadie sabe dibujar un gráfico de 4 ejes**. PCA encuentra una manera de reducir esas 4 variables a solo 2 (o 3) **perdiendo el mínimo posible de información**.

La intuición geométrica

PCA busca las direcciones en las que los datos **varían más**. Esas direcciones se llaman **componentes principales**. La primera componente (PC1) captura el máximo de varianza posible; la segunda (PC2) captura todo lo que pueda **siempre que sea perpendicular a PC1**; y así sucesivamente.

Si proyectamos los datos sobre PC1 y PC2 obtenemos un mapa 2D donde los clientes que eran parecidos en el espacio original siguen estando cerca, y los que eran diferentes siguen estando lejos. Hemos reducido de 4D a 2D conservando la mayoría de la información.

■ Analogía: la sombra de una mano

Si pones tu mano abierta delante de una luz, su sombra en la pared es una imagen 2D de un objeto 3D. La sombra **no contiene toda la información de la mano** (no se ve el grosor) pero sí la suficiente para que reconozcas que es una mano y no un pie. PCA es elegir el ángulo de la luz que produce la sombra más informativa posible, la que mejor distingue una mano de cualquier otra cosa.

La métrica clave: varianza explicada

Cada componente principal lleva asociado un porcentaje: cuánta varianza de los datos originales captura. En nuestro proyecto, PC1 explica el **54,2 %** y PC2 el **24,9 %**. Sumando: **79,1 % de la información original** conservada en solo 2 dimensiones. Suficiente para entender la estructura de los clientes.

10. Clustering con K-Means

El **clustering** (agrupamiento) es la otra gran técnica no supervisada. Su objetivo: dividir un conjunto de elementos en grupos (*clusters*) tal que **los elementos de un mismo grupo se parezcan entre sí y se diferencien de los de otros grupos**. Útil para segmentar clientes, productos, documentos, imágenes... cualquier cosa que pueda describirse con números.

K-Means: el algoritmo más popular

K-Means es el algoritmo de clustering más usado del mundo. La idea es muy intuitiva. Tú le dices al algoritmo cuántos grupos quieres (la **K**) y él hace lo siguiente:

1.	Coloca K puntos aleatorios en el espacio: serán los centros iniciales (<i>centroides</i>) de los K clusters.
2.	Asigna cada elemento al centroide más cercano . Eso forma K grupos.
3.	Recalcula cada centroide como la media de los elementos asignados a su grupo.
4.	Repite los pasos 2 y 3 hasta que los centroides ya no se muevan apenas. Cuando esto ocurre, los grupos son estables y el algoritmo ha convergido.

¿Cómo elegir el K óptimo?

Esta es la parte más delicada del clustering: **el algoritmo no te dice cuántos grupos hay, hay que decidirlo**. Existen dos métricas estándar para guiar esa decisión:

Método del codo	Se calcula la inercia (suma de distancias intra-cluster) para distintos valores de K. La inercia siempre baja al aumentar K. Buscamos el punto donde la bajada "se quiebra" formando un codo: añadir más clusters ya no mejora mucho.
Coeficiente de silueta	Para cada punto mide cuán parecido es a los de su cluster vs los del cluster más cercano. Va de -1 a +1: cuanto más alto, mejor están separados los grupos. El K que maximiza la silueta es un buen candidato.

En nuestro proyecto

El coeficiente de silueta era máximo en **K=3 (0,71)**, pero elegimos **K=4** porque permitía separar dos comportamientos importantes que K=3 mezclaba: los clientes "perdidos normales" y los "perdidos con alto Return Rate". **La interpretabilidad de negocio puede pesar más que el óptimo matemático puro.**

La solución implementada

Ahora que tenemos clara la teoría, veamos cómo se traduce todo en pasos concretos. El proyecto se ha estructurado en **cinco fases secuenciales**, cada una con su carpeta, su notebook y sus entregables.

11. Arquitectura general del proyecto

Origen	PostgreSQL 18 — base saleshealth con 17 tablas operacionales.
Motor del ETL	Python (pandas, SQLAlchemy, psycopg2) en Jupyter Notebooks.
Destino	SQLite — fichero saleshealth_dwh.db con 6 tablas dimensionales.
Análisis	Python (numpy, pandas, scikit-learn, matplotlib, seaborn).
Entorno	VS Code con kernel de Jupyter.

El flujo de datos completo es: **PostgreSQL → ETL en Python → SQLite DWH → Notebooks de análisis → CSVs y gráficos finales**. Cada fase deja sus artefactos persistentes para que la siguiente pueda continuar sin depender del estado en memoria.

12. Fase 1 — Exploración del origen

Antes de mover un solo dato hay que **entender lo que tenemos**. En esta fase nos conectamos a PostgreSQL y volcamos un retrato completo de la base operacional:

Inventario	Listado de las 17 tablas con su número de filas. Las más voluminosas: sale_item (42.555), sale (20.000) y customer (5.750).
Estructura	Para cada tabla, columnas, tipos, nullable, claves primarias y claves foráneas. Total: 96 columnas y 16 relaciones entre tablas.
Calidad	Detección de columnas con valores nulos: solo 3 columnas afectadas , lo que indica datos relativamente limpios.
Diagrama ER	Visualización del modelo entidad-relación con colores por subsistema (ventas, cliente, producto, logística, auxiliares). Es el primer entregable.

13. Fase 2 — Diseño del Star Schema

Aquí pasamos del modelo operacional al modelo analítico. Diseñamos un esquema en estrella con **una tabla de hechos y cinco dimensiones**:

fact_sales	Tabla de hechos. Granularidad: una fila por línea de venta (sale_item). Métricas: cantidad, precio, subtotal, coste unitario, margen (calculado en el ETL).
dim_customer	Cliente: nombre, email, teléfono, fecha de alta.
dim_product	Producto enriquecido con su categoría y marca (joins desde category, brand y central_product).
dim_store	Tienda enriquecida con datos del distrito, tipo de área y orientación (join con city_zone).
dim_date	Generada desde cero a partir del rango de fechas del histórico: año, trimestre, mes, semana, día de semana, marca de fin de semana.
dim_offer	Ofertas y descuentos aplicados a las ventas.

El diseño del esquema se materializa en un script SQL (02_dwh/crear_dwh.sql) con todas las sentencias CREATE TABLE, claves primarias, foráneas e índices sobre las FK del fact.

14. Fase 3 — Pipeline ETL

El ETL se implementa en un único notebook que recorre las cinco dimensiones y la fact en el orden correcto (primero las dimensiones porque la fact tiene FK que apuntan a ellas). Por cada paso se mide el tiempo y las filas extraídas/cargadas. El resumen de la ejecución:

Tabla	Filas cargadas	Tiempo
dim_date	2.191	0,39 s
dim_customer	5.750	0,18 s
dim_store	20	0,03 s
dim_product	50	0,03 s
dim_offer	1	0,03 s
fact_sales	42.555	1,44 s
TOTAL	50.567	2,10 s

Tabla 2 · Resultados del pipeline ETL.

Tras la carga se ejecutan **tres niveles de validación**: (1) recuento de filas en cada tabla; (2) integridad referencial — comprobación de que **cero FKs en fact_sales son huérfanas**, todas apuntan a una fila válida en su dimensión; (3) calidad de datos — detección de líneas con coste cero, márgenes negativos, productos sin marca, totales económicos.

Resultado: ingresos totales **9.678.678 €**, margen total **3.888.777 €** (margen del ~40 %), integridad 100 % correcta.

15. Fase 4 — Cálculo de métricas

Con el DWH listo, calculamos las tres métricas teóricas explicadas en la Parte II. Para cada cliente generamos:

CLTV	Media: 83.353 € · Mediana: 60 € . La gigantesca diferencia entre media y mediana revela una distribución muy asimétrica : unos pocos clientes acumulan la mayor parte del valor (efecto Pareto).
Churn	36,0 % activos · 2,5 % en riesgo · 61,6 % perdidos. Más del 60 % de los clientes llevan más de un año sin comprar — un dato preocupante desde el punto de vista de retención.
Return Rate	Media 8,6 % . Solo 1.124 clientes (19,5 %) han hecho devoluciones. Curiosidad: hay clientes con return rate > 1 (devolvieron más de lo que compraron en el mismo periodo) — son devoluciones de compras anteriores al rango temporal del dataset.

Las tres métricas se consolidan en el fichero `clientes_final.csv`, que es el input de la siguiente fase.

16. Fase 5 — PCA y K-Means

Última fase analítica. Sobre los 5.750 clientes con sus 4 features (CLTV en log10, días desde última compra, frecuencia, return rate) estandarizadas con StandardScaler:

PCA

Reducimos a 2 componentes: **PC1 explica 54,2 %** de la varianza y **PC2 explica 24,9 %**, sumando un **79,1 %** de información retenida. El biplot revela que PC1 está dominada por la **frecuencia de compra** (eje horizontal: clientes que compran mucho a la derecha, poco a la izquierda) y PC2 por el **return rate** (eje vertical: clientes que devuelven mucho arriba). Estas dos dimensiones bastan para explicar el grueso del comportamiento.

K-Means

Probamos k de 2 a 8 con método del codo y silueta. La silueta máxima estaba en **k=3 (0,71)** pero, como ya explicamos, elegimos **k=4** por interpretabilidad de negocio. El resultado son cuatro segmentos muy bien diferenciados que veremos en la Parte IV.

Resultados y conclusiones

17. Interpretación de los segmentos

Cada cluster tiene un perfil muy distinto. Los nombres están elegidos para que cualquier persona de negocio pueda entenderlos sin necesidad de mirar los números:

#	Segmento	N	CLTV medio	Días sin comprar	Frecuencia	Estrategia recomendada
0	Regular activo	2.265	67 €	214	1,0	Cliente esporádico que sí está vivo. Aumentar ticket medio con cross-selling.
1	Perdido	2.295	66 €	1.290	1,0	Lleva años sin comprar. Decidir entre campaña agresiva de reactivación o descartarlo y dejar de invertir en él.
2	VIP / Champion	750	638.596 €	119	20,0	El cliente premium. Genera la mayor parte de los ingresos y sigue activo. Retención prioritaria, programa de fidelización.
3	Devolutivo	440	64 €	764	1,0	Return Rate > 1. Compra y devuelve más de lo que se queda. Revisar experiencia, política de devoluciones, posibles fraudes.

Tabla 3 · Perfil de los cuatro segmentos identificados.

El dato más impactante es el contraste entre el cluster VIP (750 clientes con CLTV medio de 638.596 €) y el resto (~5.000 clientes con CLTV medio de ~66 €). Es la **regla 80/20 empírica del retail** apareciendo de forma muy nítida: una minoría de clientes concentra una mayoría desproporcionada del valor.

18. Recomendaciones de negocio

Más allá de los entregables técnicos, el proyecto sirve para que la empresa tome decisiones concretas. Estas serían las cuatro líneas de acción derivadas directamente del análisis:

1. Programa VIP	Los 750 clientes del cluster Champion son el activo más valioso de la empresa. Deberían tener un trato diferenciado: gestor personal, descuentos exclusivos, lanzamientos en preview, encuestas de satisfacción periódicas. Su pérdida es literalmente catastrófica para la facturación.
2. Campaña de reactivación selectiva	Sobre los 2.295 clientes "perdidos", segmentar por valor histórico antes de decidir si invertir en reactivarlos o no. Quienes tuvieron alto CLTV en su día merecen un esfuerzo; los demás, probablemente no.
3. Auditoría del segmento devolutivo	Los 440 clientes con Return Rate > 1 son una anomalía que merece investigación: ¿problema de calidad de producto?, ¿proceso de venta engañoso?, ¿posible fraude (compra-uso-devolución)? El primer paso es entender el porqué antes de actuar.
4. Aumentar ticket medio en regulares	Los 2.265 clientes activos pero con CLTV bajo representan el mayor potencial de crecimiento orgánico. Estrategias de cross-selling y up-selling, recomendaciones personalizadas y bundles temáticos pueden multiplicar su valor sin coste de adquisición.

19. Cómo encaja todo: el cuadro completo

Para cerrar, vamos a recorrer el camino completo en una sola página. Si te ha quedado alguna duda en algún paso, vuelve aquí y verás cómo cada pieza encaja con la siguiente:

Empezamos con un problema de negocio: una empresa de productos de salud con datos en cuatro sistemas distintos que no se hablan. **Imposible analizar.**

Identificamos que los datos operacionales (OLTP) y los analíticos (OLAP) tienen fines opuestos: los primeros están diseñados para escribir rápido, los segundos para leer rápido. **Necesitamos un destino analítico.**

Diseñamos ese destino como un Data Warehouse con esquema en estrella (método Kimball): una tabla central de hechos rodeada de cinco dimensiones desnormalizadas. **Estructura simple y rápida de consultar.**

Construimos un proceso ETL en Python que extrae de PostgreSQL, transforma (limpia, calcula margen, genera la dimensión fecha) y carga en SQLite. Validamos integridad y calidad. **Datos confiables y listos para análisis.**

Calculamos tres métricas sobre cada cliente: CLTV (cuánto vale), Churn Risk (cómo de activo está), Return Rate (cuánto devuelve). **Cuatro features numéricas que describen el comportamiento.**

Aplicamos aprendizaje no supervisado: PCA para reducir las 4 dimensiones a 2 visualizables, K-Means para agrupar automáticamente a los 5.750 clientes en segmentos. **Patrones que ningún humano vería a simple vista.**

Interpretamos los cuatro grupos resultantes en lenguaje de negocio: Champion, Regular, Perdido, Devolutivo. **De los datos a las decisiones.**

La idea de fondo, en una frase

Hemos transformado **71.934 filas dispersas en 17 tablas operacionales** en **4 segmentos de cliente accionables**, y en el camino hemos pasado por todas las etapas clásicas de un proyecto de datos moderno: modelado dimensional, ETL, métricas de negocio, reducción de dimensionalidad y clustering.

Documento didáctico — Proyecto Final de Gestión de Datos · UAX 2026